

Demonstração da equação do Filtro Ótimo de Lee para ruído Speckle

Dado um sinal de entrada $f(x)$, ao passá-lo por um sistema dinâmico que gere o ruído Speckle, o sinal de saída $g(x)$ pode ser modelado de acordo com a seguinte equação:

$$g(x) = f(x) \cdot (1 + \gamma \cdot N(0,1))$$

Em que, $N(0,1)$ é um processo estocástico com uma função densidade de probabilidade igual função gaussiana com média $E\{N(0,1)\} = 0$ e variância $Var\{N(0,1)\} = 1$. Para tentar estimar $f(x)$ a partir de $g(x)$, podemos assumir uma relação afim entre o estimador $\hat{f}(x)$ e a saída $g(x)$:

$$\hat{f}(x) = a + b \cdot g(x)$$

Para determinar os coeficientes a e b , podemos utilizar a técnica de otimização não-linear sem restrição, em que deriva-se o valor médio da diferença quadrática entre $\hat{f}(x)$ e $f(x)$ em relação ao vetor de coeficientes e iguala-se ao vetor de zeros:

$$\frac{\partial}{\partial a} \left(E \{ (\hat{f}(x) - f(x))^2 \} \right) = E \left\{ 2 \cdot (\hat{f}(x) - f(x)) \cdot \frac{\partial \hat{f}}{\partial a}(x) \right\} = 0 \rightarrow E \{ (\hat{f}(x) - f(x)) \} = 0$$

$$\frac{\partial}{\partial b} \left(E \{ (\hat{f}(x) - f(x))^2 \} \right) = E \left\{ 2 \cdot (\hat{f}(x) - f(x)) \cdot \frac{\partial \hat{f}}{\partial b}(x) \right\} = 0 \rightarrow E \{ (\hat{f}(x) - f(x)) \cdot g(x) \} = 0$$

Antes de continuarmos, precisamos demonstrar algumas relações que derivam do fato de assumir que $f(x)$ e $N(0,1)$ são processos estocásticos independentes:

(i) Relação entre $E\{g(x)\}$ e $E\{f(x)\}$:

$$E\{g(x)\} = E\{f(x) \cdot (1 + \gamma \cdot N(0,1))\} = E\{f(x)\} \cdot E\{1 + \gamma \cdot N(0,1)\} = E\{f(x)\}$$

(ii) Relação entre $E\{(g(x))^2\}$ e $E\{(f(x))^2\}$:

$$E\{(g(x))^2\} = E\{(f(x))^2 \cdot (1 + \gamma \cdot N(0,1))^2\} = E\{(f(x))^2\} \cdot E\{1 + 2 \cdot \gamma \cdot N(0,1) + \gamma^2 \cdot (N(0,1))^2\}$$

$$E\{(g(x))^2\} = E\{(f(x))^2\} \cdot [1 + \gamma^2 \cdot (Var(N(0,1)) + (E\{N(0,1)\})^2)] = E\{(f(x))^2\} \cdot (1 + \gamma^2)$$

$$E\{(f(x))^2\} = \frac{E\{(g(x))^2\}}{1 + \gamma^2}$$

(iii) Relação entre $E\{f(x) \cdot g(x)\}$ e $E\{(g(x))^2\}$:

$$E\{f(x) \cdot g(x)\} = E\left\{(f(x))^2 \cdot (1 + \gamma \cdot N(0,1))\right\} = E\left\{(f(x))^2\right\} \cdot E\{1 + \gamma \cdot N(0,1)\} = E\left\{(f(x))^2\right\}$$

$$E\{f(x) \cdot g(x)\} = \frac{E\left\{(g(x))^2\right\}}{1 + \gamma^2}$$

Agora podemos continuar em determinar o valor dos coeficientes a e b . Começando com a equação de derivação em relação a a :

$$E\{a + b \cdot g(x) - f(x)\} = E\left\{a + b \cdot (f(x) \cdot (1 + \gamma \cdot N(0,1))) - f(x)\right\} = 0$$

$$E\{a + f(x) \cdot (-1 + b + b \cdot \gamma \cdot N(0,1))\} = a + E\{f(x)\} \cdot E\{-1 + b + b \cdot \gamma \cdot N(0,1)\} = 0$$

$$a + E\{f(x)\} \cdot (b - 1) = 0 \rightarrow a + E\{g(x)\} \cdot (b - 1) = 0$$

$$a + \mu_g \cdot b = \mu_g$$

Agora a equação de derivação em relação a b :

$$E\{(a + b \cdot g(x) - f(x)) \cdot g(x)\} = E\{a \cdot g(x) + b \cdot (g(x))^2 - f(x) \cdot g(x)\} = 0$$

$$a \cdot E\{g(x)\} + b \cdot E\{(g(x))^2\} - E\{f(x) \cdot g(x)\} = 0$$

$$a \cdot E\{g(x)\} + b \cdot E\{(g(x))^2\} - \frac{E\{(g(x))^2\}}{1 + \gamma^2} = 0$$

$$\mu_g \cdot a + (\sigma_g^2 + \mu_g^2) \cdot b = \frac{\sigma_g^2 + \mu_g^2}{1 + \gamma^2}$$

Então, temos o seguinte sistema linear de duas equações e duas incógnitas:

$$\begin{cases} a + \mu_g \cdot b = \mu_g \\ \mu_g \cdot a + (\sigma_g^2 + \mu_g^2) \cdot b = \frac{\sigma_g^2 + \mu_g^2}{1 + \gamma^2} \end{cases}$$

Multiplicando a primeira equação do sistema por μ_g e subtraindo esta da segunda temos que:

$$\sigma_g^2 \cdot b = \frac{\sigma_g^2 + \mu_g^2}{1 + \gamma^2} - \mu_g^2 = \frac{\sigma_g^2 + \mu_g^2 - \mu_g^2 \cdot (1 + \gamma^2)}{1 + \gamma^2} = \frac{\sigma_g^2 - \mu_g^2 \cdot \gamma^2}{1 + \gamma^2}$$

$$b = \frac{\sigma_g^2 - \mu_g^2 \cdot \gamma^2}{\sigma_g^2 \cdot (1 + \gamma^2)}$$

Agora resolvendo a primeira equação para determinar o valor de a :

$$a = \mu_g \cdot (1 - b) = \mu_g \cdot \left(1 - \frac{\sigma_g^2 - \mu_g^2 \cdot \gamma^2}{\sigma_g^2 \cdot (1 + \gamma^2)}\right) = \mu_g \cdot \frac{\sigma_g^2 \cdot (1 + \gamma^2) - \sigma_g^2 + \mu_g^2 \cdot \gamma^2}{\sigma_g^2 \cdot (1 + \gamma^2)} = \mu_g \cdot \frac{\gamma^2 \cdot (\sigma_g^2 + \mu_g^2)}{\sigma_g^2 \cdot (1 + \gamma^2)}$$

$$a = \mu_g \cdot \frac{\gamma^2}{1 + \gamma^2} \cdot \frac{\sigma_g^2 + \mu_g^2}{\sigma_g^2}$$

Se fizermos $a = \mu_g \cdot \alpha_s$, temos que $\alpha_s = 1 - b$, que implica em $b = 1 - \alpha_s$, em que:

$$\alpha_s = \frac{\gamma^2}{1 + \gamma^2} \cdot \frac{\sigma_g^2 + \mu_g^2}{\sigma_g^2} = \frac{\gamma^2}{1 + \gamma^2} \cdot \frac{E\{(g(x))^2\}}{\sigma_g^2}$$

A última tarefa é determinar o valor de γ . Para isto, precisamos determinar a relação entre $Var\{g(x)\}$ e $Var\{f(x)\}$. E como esta relação se comporta em uma região em que $f(x)$ seria homogêneo.

$$Var\{g(x)\} = E\{(g(x))^2\} - (E\{g(x)\})^2 = E\{(f(x))^2\} \cdot (1 + \gamma^2) - (E\{g(x)\})^2$$

$$Var\{g(x)\} = [Var\{f(x)\} + (E\{f(x)\})^2] \cdot (1 + \gamma^2) - (E\{g(x)\})^2$$

$$Var\{g(x)\} = Var\{f(x)\} \cdot (1 + \gamma^2) + (E\{g(x)\})^2 \cdot (1 + \gamma^2) - (E\{g(x)\})^2$$

$$Var\{g(x)\} = Var\{f(x)\} \cdot (1 + \gamma^2) + (E\{g(x)\})^2 \cdot \gamma^2$$

$$\sigma_g^2 = \sigma_f^2 \cdot (1 + \gamma^2) + \mu_g^2 \cdot \gamma^2$$

Em uma região homogênea temos que $f_H(x) = K$, em que K é uma constante qualquer, temos que:

$$E\{f_H(x)\} = E\{K\} = K \rightarrow \mu_{f_H} = K$$

$$Var\{f_H(x)\} = E\{(f_H(x))^2\} - (E\{f_H(x)\})^2 = E\{K^2\} - K^2 = K^2 - K^2 = 0 \rightarrow \sigma_{f_H} = 0$$

Aplicando a variância de f em uma região homogênea na equação da variância de g é possível determinar o valor de γ em função de variância e da média de g em uma região homogênea:

$$\sigma_{g_H}^2 = \mu_{g_H}^2 \cdot \gamma^2 \rightarrow \gamma^2 = \frac{\sigma_{g_H}^2}{\mu_{g_H}^2}$$

Assim, o valor de α_s pode ser mudado para:

$$\frac{\gamma^2}{1 + \gamma^2} = \frac{\frac{\sigma_{g_H}^2}{\mu_{g_H}^2}}{1 + \frac{\sigma_{g_H}^2}{\mu_{g_H}^2}} = \frac{\frac{\sigma_{g_H}^2}{\mu_{g_H}^2}}{\frac{\mu_{g_H}^2 + \sigma_{g_H}^2}{\mu_{g_H}^2}} = \frac{\sigma_{g_H}^2}{\mu_{g_H}^2 + \sigma_{g_H}^2} = \frac{\sigma_{g_H}^2}{E\{(g_H(x))^2\}}$$

$$\alpha_s = \frac{\sigma_{g_H}^2}{E\{(g_H(x))^2\}} \cdot \frac{E\{(g(x))^2\}}{\sigma_g^2} = \frac{c_{g_H}}{c_g}$$

Por fim, temos que a equação do estimador ótimo é:

$$\hat{f}(x) = \mu_g \cdot \alpha_s + (1 - \alpha_s) \cdot g(x)$$

Em que $\alpha_s = \frac{c_{g_H}}{c_g}$ para $c_{g_H} = \frac{\sigma_{g_H}^2}{E\{(g_H(x))^2\}}$ e $c_g = \frac{\sigma_g^2}{E\{(g(x))^2\}}$

A estratégia do Filtro de Lee é calcular as estatística de g de maneira local, ou seja, para cada pixel, ele aplica uma janela móvel de tamanho fixo para calcular μ_g e $E\{(g(x))^2\}$ para chegar em σ_g . Ele faz o mesmo para uma região em que f seria homogêneo para calcular as estatísticas de g_H , mas estas só precisam ser calculadas uma única vez. Assim, α_s é calculada para cada pixel.